Ανάλυση Ακουστικών Χαρακτηριστικών και Στατιστική Μοντελοποίηση για Αναγνώριση Συναισθήματος Ομιλίας

Αναγνώριση Συναισθήματος από Ομιλία: Στατιστική Ανάλυση - Διαχωρισμός Θυμού & Λύπης με χρήση MFCCs & PCA.

Γιαννάτος Δημήτριος

ΑΜ: 20127

Τμήμα ΗΜΜΥ

Επιβλέπων: Δρ. Κ. Παναγιώτης Ζέρβας

Πάτρα, Φεβρουάριος 2026

1 Περίληψη

Η παρούσα εργασία πραγματεύεται το ζήτημα της Αναγνώρισης Συναισθήματος από την Ομιλία (Speech Emotion Recognition - SER), ενός ταχέως αναπτυσσόμενου κλάδου της Επικοινωνίας Ανθρώπου-Υπολογιστή. Αντικείμενο της μελέτης είναι η διερεύνηση της δυνατότητας αυτόματου διαχωρισμού μεταξύ δύο συναισθημάτων με έντονη αντίθεση στη διεγερτικότητα: του Θυμού (Anger) και της Λύπης (Sadness).

Για την υλοποίηση της έρευνας χρησιμοποιήθηκε το πρότυπο σύνολο δεδομένων TESS (Toronto Emotional Speech Set). Η μεθοδολογία περιλάμβανε την ανάπτυξη λογισμικού σε γλώσσα Python με χρήση της βιβλιοθήκης Librosa για την ψηφιακή επεξεργασία σήματος. Εξήχθησαν κρίσιμα ακουστικά χαρακτηριστικά, συμπεριλαμβανομένων της Ενέργειας (RMS Energy), της Θεμελιώδους Συχνότητας (F0) και των Συντελεστών (MFCCs). Στη συνέχεια, εφαρμόστηκε η στατιστική μέθοδος Ανάλυσης Κυρίων Συνιστωσών (PCA) για τη μείωση των διαστάσεων και την οπτικοποίηση των δεδομένων.

Τα αποτελέσματα της ανάλυσης κατέδειξαν σαφή διαχωρισμό των δύο συναισθημάτων. Παρατηρήθηκε ότι ο Θυμός χαρακτηρίζεται από σημαντικά υψηλότερη ενέργεια και φασματικό κέντρο σε σύγκριση με τη Λύπη. Η εφαρμογή του PCA επιβεβαίωσε τη δημιουργία δύο διακριτών cluster με ελάχιστη επικάλυψη, αποδεικνύοντας ότι τα επιλεγμένα ακουστικά χαρακτηριστικά επαρκούν για την αξιόπιστη κατηγοριοποίηση των συγκεκριμένων συναισθηματικών καταστάσεων.

Περιεχόμενα

1 Περίληψη 2

2 Κεφάλαιο 1 – Εισαγωγή 5

2.1 Γενικό Πλαίσιο και Αντικείμενο Μελέτης 5

2.2 Διατύπωση του Προβλήματος 5

2.3 Στόχοι της Εργασίας 5

2.4 Σκοπιμότητα και Εφαρμογές 6

2.5 Δομή της Εργασίας 6

3 Κεφάλαιο 2 – Θεωρητικό Υπόβαθρο 7

3.1 Ψηφιακή Επεξεργασία Σήματος Ομιλίας 7

3.2 Μηχανισμός Παραγωγής και Συναίσθημα 7

3.3 Εξαγωγή Χαρακτηριστικών (Feature Extraction) 7

3.3.1 Χαρακτηριστικά Πεδίου Χρόνου 7

3.3.2 Φασματικά Χαρακτηριστικά 8

3.3.3 Κεπστρικά Χαρακτηριστικά (MFCCs) 8

3.4 Μείωση Διαστάσεων με PCA 8

4 Κεφάλαιο 3 – Δεδομένα & Εργαλεία Λογισμικού 9

4.1 Περιγραφή Συνόλου Δεδομένων (Dataset) 9

4.1.1 Δομή και Περιεχόμενο 9

4.1.2 Επιλογή Υποσυνόλου Δεδομένων 9

4.2 Περιβάλλον Ανάπτυξης και Γλώσσα Προγραμματισμού 10

4.3 Βιβλιοθήκες Λογισμικού 10

5 Κεφάλαιο 4 – Μεθοδολογία & Υλοποίηση 11

5.1 Γενική Αρχιτεκτονική Συστήματος (Pipeline) 11

5.2 Διαδικασία Φόρτωσης και Προεπεξεργασίας 11

5.3 Αλγόριθμος Εξαγωγής Χαρακτηριστικών (MFCCs) 11

5.4 Στατιστική Ανάλυση και PCA 12

6 Κεφάλαιο 5 – Αποτελέσματα 12

6.1 Ανάλυση Ακουστικών Χαρακτηριστικών 12

6.1.1 Κατανομές Ενέργειας και Συχνότητας 13

6.1.2 Φασματικό Κέντρο (Spectral Centroid) 13

6.2 Συσχέτιση Χαρακτηριστικών (Correlation Matrix)..... 14
6.3 Οπτικοποίηση PCA και Διαχωρισμός..... 15

7 Κεφάλαιο 6 – Συζήτηση & Συμπεράσματα 17
7.1 Ανασκόπηση της Έρευνας..... 17
7.2 Ερμηνεία των Αποτελεσμάτων 17
7.2.1 Η Φυσιολογία του Θυμού και της Λύπης..... 17
7.2.2 Η Αξία των MFCCs..... 18
7.3 Περιορισμοί της Μελέτης..... 18
7.4 Προτάσεις για Μελλοντική Έρευνα 19
7.5 Τελικά Συμπεράσματα..... 19

8 Κεφάλαιο 7 - Βιβλιογραφία 19

2 Κεφάλαιο 1 – Εισαγωγή

2.1 Γενικό Πλαίσιο και Αντικείμενο Μελέτης

Η ανθρώπινη φωνή αποτελεί το πλέον φυσικό, άμεσο και αποδοτικό μέσο επικοινωνίας. Ωστόσο, η πληροφορία που μεταδίδεται μέσω της ομιλίας δεν περιορίζεται αποκλειστικά στο γλωσσικό περιεχόμενο (το "τι" λέγεται). Μια εξίσου σημαντική πτυχή της επικοινωνίας είναι η παραγλωσσική πληροφορία, η οποία αφορά το "πώς" εκφέρεται ο λόγος και αποκαλύπτει τη συναισθηματική κατάσταση, τις προθέσεις και την ψυχολογική διάθεση του ομιλητή . Η επιστημονική μελέτη αυτών των παραγόντων αποτελεί τον πυρήνα της "Συναισθηματικής Υπολογιστικής" (Affective Computing) **[1]**.

Στο πεδίο της Μηχανικής Μάθησης και της Ψηφιακής Επεξεργασίας Σήματος, ο κλάδος της **Αναγνώρισης Συναισθήματος από την Ομιλία (Speech Emotion Recognition - SER)** παρουσιάζει ραγδαία ανάπτυξη. Παρά την πρόοδο στην αναγνώριση ομιλίας (Speech-to-Text), η ικανότητα των υπολογιστικών συστημάτων να αντιλαμβάνονται τον συναισθηματικό χρωματισμό της φωνής παραμένει μια σύνθετη τεχνική πρόκληση **[2]**.

2.2 Διατύπωση του Προβλήματος

Το κεντρικό πρόβλημα που καλείται να διερευνήσει η εργασία είναι η δυσκολία ποσοτικοποίησης του ανθρώπινου συναισθήματος. Ενώ για τον άνθρωπο η διάκριση μεταξύ ενός "θυμωμένου" και ενός "λυπημένου" ομιλητή είναι ενστικτώδης, για έναν ηλεκτρονικό υπολογιστή απαιτείται η μετατροπή του ηχητικού κύματος σε μετρήσιμα μαθηματικά χαρακτηριστικά **[3].**

Συγκεκριμένα, τίθεται το ερώτημα:

*Είναι εφικτός ο σαφής διαχωρισμός μεταξύ των συναισθημάτων του **Θυμού (Angry)** και της **Λύπης (Sad)**, βασιζόμενοι αποκλειστικά στα ακουστικά χαρακτηριστικά του σήματος, όπως η ενέργεια και η συχνότητα;*

2.3 Στόχοι της Εργασίας

Ο πρωταρχικός στόχος της παρούσας μελέτης είναι η ανάπτυξη μιας διαδικασίας (pipeline) επεξεργασίας ήχου για την εξαγωγή χαρακτηριστικών

και τη στατιστική ανάλυση συναισθηματικής ομιλίας. Για την υλοποίηση της έρευνας επιλέχθηκε το πρότυπο σύνολο δεδομένων **TESS** (Toronto Emotional Speech Set) **[4].**

Αναλυτικότερα, οι επιμέρους στόχοι είναι:

1. **Εξαγωγή Ακουστικών Χαρακτηριστικών:** Ο υπολογισμός κρίσιμων παραμέτρων όπως η Ενέργεια (RMS Energy) και οι συντελεστές MFCCs **[5].**
2. **Στατιστική Ανάλυση:** Η σύγκριση των κατανομών των χαρακτηριστικών μεταξύ των δύο συναισθημάτων.
3. **Οπτικοποίηση Δεδομένων:** Η χρήση τεχνικών μείωσης διαστάσεων (PCA) για την εποπτική επιβεβαίωση του διαχωρισμού **[6].**
4. **Υλοποίηση Λογισμικού:** Η χρήση της γλώσσας Python και της βιβλιοθήκης Librosa **[7].**

2.4 Σκοπιμότητα και Εφαρμογές

Η επιτυχής αναγνώριση συναισθημάτων έχει κρίσιμη σημασία για πληθώρα σύγχρονων εφαρμογών **[8] :**

- **Αλληλεπίδραση Ανθρώπου-Υπολογιστή (HCI):** Ανάπτυξη ψηφιακών βοηθών που προσαρμόζουν τη συμπεριφορά τους.
- **Κέντρα Εξυπηρέτησης (Call Centers):** Αυτόματος εντοπισμός δυσαρεστημένων ή θυμωμένων πελατών.
- **Ιατρική Παρακολούθηση:** Υποβοήθηση στη διάγνωση ψυχικών διαταραχών, όπου η "επίπεδη" ομιλία αποτελεί σύμπτωμα.

2.5 Δομή της Εργασίας

Η εργασία οργανώνεται ως εξής:

- Στο **Κεφάλαιο 2** παρουσιάζεται το απαραίτητο θεωρητικό υπόβαθρο.
- Στο **Κεφάλαιο 3** περιγράφονται τα δεδομένα και τα εργαλεία λογισμικού.
- Στο **Κεφάλαιο 4** αναλύεται η μεθοδολογία και ο κώδικας.
- Στο **Κεφάλαιο 5** παρατίθενται τα αποτελέσματα και τα γραφήματα.
- Στο **Κεφάλαιο 6**, καταγράφονται τα συμπεράσματα.

3 Κεφάλαιο 2 – Θεωρητικό Υπόβαθρο

3.1 Ψηφιακή Επεξεργασία Σήματος Ομιλίας

Η ομιλία είναι ένα αναλογικό σήμα που μεταβάλλεται συνεχώς στον χρόνο. Για την επεξεργασία του από ψηφιακά συστήματα, απαιτείται η μετατροπή του σε μια ακολουθία αριθμών μέσω της διαδικασίας της **δειγματοληψίας (sampling)**.

Το ψηφιακό σήμα ήχου αναπαρίσταται ως ένας μονοδιάστατος πίνακας τιμών, όπου κάθε τιμή αντιστοιχεί στο πλάτος της πίεσης του αέρα σε μια συγκεκριμένη χρονική στιγμή **[9].**

3.2 Μηχανισμός Παραγωγής και Συναίσθημα

Το συναίσθημα επηρεάζει άμεσα τη φυσιολογία της παραγωγής ομιλίας.

- **Θυμός (Anger):** Προκαλεί μυϊκή ένταση, ταχύτερη αναπνοή και αυξημένη υπογλωττιδική πίεση, οδηγώντας σε φωνή με μεγαλύτερη ένταση και υψηλότερο τόνο **[10].**
- **Λύπη (Sadness):** Σχετίζεται με χαλάρωση των μυών και μειωμένη ενέργεια, οδηγώντας σε πιο αργή και μονότονη ομιλία **[11]** .

3.3 Εξαγωγή Χαρακτηριστικών (Feature Extraction)

Η εξαγωγή χαρακτηριστικών είναι η διαδικασία μείωσης του όγκου των δεδομένων, κρατώντας μόνο την πληροφορία που είναι χρήσιμη για τη διάκριση των συναισθημάτων.

3.3.1 Χαρακτηριστικά Πεδίου Χρόνου

 Ενέργεια (RMS Energy): Η Ενέργεια Ρίζας Μέσου Τετραγώνου υπολογίζει τη μέση ισχύ του σήματος και αντιστοιχεί στην ακουστική ένταση (loudness).

 Ρυθμός Μηδενικών Διελεύσεων (ZCR): Μετρά τις εναλλαγές προσήμου του σήματος και σχετίζεται με την παρουσία θορύβου ή υψηλών συχνοτήτων **[12].**

3.3.2 Φασματικά Χαρακτηριστικά

- **Θεμελιώδης Συχνότητα (Pitch / F0):** Αντιστοιχεί στον ρυθμό ταλάντωσης των φωνητικών χορδών. Είναι ίσως το πιο σημαντικό προσωδιακό χαρακτηριστικό για το συναίσθημα.

- **Φασματικό Κέντρο (Spectral Centroid):** Υποδεικνύει το "κέντρο βάρους" του φάσματος. Υψηλές τιμές συνδέονται με τον θυμό ("λαμπερός" ήχος).

3.3.3 Κεπστρικά Χαρακτηριστικά (MFCCs)

Οι **Συντελεστές Mel-Frequency Cepstral Coefficients (MFCCs)** αποτελούν το πρότυπο στην αναγνώριση φωνής. Μιμούνται την ανθρώπινη ακοή (κλίμακα Mel), η οποία είναι πιο ευαίσθητη στις χαμηλές συχνότητες παρά στις υψηλές.

Επειδή περιγράφουν τη "χροιά" της φωνής ανεξάρτητα από το τι λέει ο ομιλητής, τα MFCCs θεωρούνται εξαιρετικά αποδοτικά για την κατηγοριοποίηση συναισθημάτων **[13].**

3.4 Μείωση Διαστάσεων με PCA

Η ανάλυση ήχου παράγει δεδομένα υψηλής διαστασιμότητας (π.χ. 13 MFCCs ανά δείγμα). Η **Ανάλυση Κυρίων Συνιστωσών (PCA)** είναι μια στατιστική μέθοδος που μετασχηματίζει τα δεδομένα σε ένα νέο σύστημα αξόνων, διατηρώντας τη μέγιστη δυνατή πληροφορία (διακύμανση) **[14].** Στην παρούσα εργασία, η PCA χρησιμοποιείται για την προβολή των δεδομένων σε 2 διαστάσεις (2D), επιτρέποντας την οπτική επαλήθευση του διαχωρισμού μεταξύ Θυμού και Λύπης.

4 Κεφάλαιο 3 – Δεδομένα & Εργαλεία Λογισμικού

4.1 Περιγραφή Συνόλου Δεδομένων (Dataset)

Για τις ανάγκες της παρούσας πτυχιακής εργασίας χρησιμοποιήθηκε το σύνολο δεδομένων **Toronto Emotional Speech Set (TESS)**. Το συγκεκριμένο dataset δημιουργήθηκε από το Πανεπιστήμιο του Τορόντο και αποτελεί σημείο αναφοράς στην έρευνα γύρω από την αναγνώριση συναισθήματος, λόγω της υψηλής ακουστικής του ποιότητας και της καθαρότητας των ηχογραφήσεων [4].

4.1.1 Δομή και Περιεχόμενο

Το TESS περιλαμβάνει ηχογραφήσεις από δύο ηθοποιούς (μια νεότερη, 26 ετών, και μια μεγαλύτερη, 64 ετών), οι οποίες εκφέρουν ένα σύνολο 200 πρότυπων λέξεων (π.χ. "Say the word *back*", "Say the word *goose*").

Κάθε λέξη εκφέρεται με 7 διαφορετικά συναισθήματα:

- Θυμός (Anger)
- Αηδία (Disgust)
- Φόβος (Fear)
- Ευτυχία (Happiness)
- Ευχάριστη έκπληξη (Pleasant surprise)
- Λύπη (Sadness)
- Ουδέτερο (Neutral)

Συνολικά, η βάση δεδομένων περιέχει 2.800 αρχεία ήχου σε μορφή **.wav.**

4.1.2 Επιλογή Υποσυνόλου Δεδομένων

Στην παρούσα μελέτη, εστιάζουμε αποκλειστικά στον διαχωρισμό δύο συναισθημάτων με έντονη αντίθεση στη διεγερτικότητα (arousal). Ως εκ τούτου, απομονώθηκαν και χρησιμοποιήθηκαν μόνο τα αρχεία που αντιστοιχούν στις κατηγορίες:

1. **Angry (Θυμός):** Υψηλή ενέργεια/διέγερση.
2. **Sad (Λύπη):** Χαμηλή ενέργεια/διέγερση.

Η επιλογή αυτή επιτρέπει την σαφέστερη μελέτη των ακουστικών χαρακτηριστικών που διαφοροποιούν τις δύο καταστάσεις, ελαχιστοποιώντας την πολυπλοκότητα που εισάγουν τα ενδιάμεσα συναισθήματα [5].

4.2 Περιβάλλον Ανάπτυξης και Γλώσσα Προγραμματισμού

Η υλοποίηση της διαδικασίας επεξεργασίας και ανάλυσης πραγματοποιήθηκε εξ ολοκλήρου στη γλώσσα προγραμματισμού **Python**. Η Python αποτελεί σήμερα την κυρίαρχη επιλογή στον χώρο της Επιστήμης Δεδομένων (Data Science) και της Μηχανικής Μάθησης, χάρη στην ευκολία σύνταξης και το πλούσιο οικοσύστημα βιβλιοθηκών που διαθέτει **[15].**

Για τη συγγραφή και εκτέλεση του κώδικα χρησιμοποιήθηκε περιβάλλον **Jupyter Notebook**, το οποίο επιτρέπει την τμηματική εκτέλεση κώδικα και την άμεση οπτικοποίηση των αποτελεσμάτων.

4.3 Βιβλιοθήκες Λογισμικού

Για την επίτευξη των στόχων της εργασίας, αξιοποιήθηκαν οι ακόλουθες εξειδικευμένες βιβλιοθήκες:

- **Librosa:** Η βασική βιβλιοθήκη για την ανάλυση ήχου και μουσικής στην Python. Χρησιμοποιήθηκε για τη φόρτωση των αρχείων **.wav,** την εξαγωγή των χαρακτηριστικών MFCCs και τον υπολογισμό του φασματογραφήματος [7].
- **NumPy & Pandas:** Χρησιμοποιήθηκαν για τη διαχείριση των πολυδιάστατων πινάκων (arrays) και την οργάνωση των δεδομένων σε δομημένη μορφή (DataFrames) πριν την ανάλυση [16].
- **Scikit-learn:** Μια από τις δημοφιλέστερες βιβλιοθήκες μηχανικής μάθησης. Στην εργασία μας χρησιμοποιήθηκε για την υλοποίηση του αλγορίθμου PCA (Principal Component Analysis) και την κανονικοποίηση (scaling) των δεδομένων [17].
- **Matplotlib:** Χρησιμοποιήθηκε για τη δημιουργία των γραφημάτων, όπως τα διαγράμματα κυματομορφής και τα διαγράμματα διασποράς (scatter plots) του PCA [18].

5 Κεφάλαιο 4 – Μεθοδολογία & Υλοποίηση

5.1 Γενική Αρχιτεκτονική Συστήματος (Pipeline)

Η μεθοδολογία που αναπτύχθηκε για την αναγνώριση και τον διαχωρισμό των συναισθημάτων ακολουθεί μια κλασική ροή εργασίας (pipeline) μηχανικής μάθησης. Η διαδικασία αποτελείται από τέσσερα διακριτά στάδια:

1. **Φόρτωση Δεδομένων:** Ανάγνωση των αρχείων ήχου και αντιστοίχιση με τις ετικέτες (labels) των συναισθημάτων.
2. **Προ-επεξεργασία (Preprocessing):** Κανονικοποίηση και έλεγχος διάρκειας των σημάτων.
3. **Εξαγωγή Χαρακτηριστικών (Feature Extraction):** Υπολογισμός των συντελεστών MFCCs για κάθε αρχείο.
4. **Μείωση Διαστάσεων (Dimensionality Reduction):** Εφαρμογή του αλγορίθμου PCA για την οπτικοποίηση των αποτελεσμάτων.

5.2 Διαδικασία Φόρτωσης και Προεπεξεργασίας

Για τη φόρτωση των αρχείων .wav χρησιμοποιήθηκε η συνάρτηση load της βιβλιοθήκης **Librosa**. Όλα τα σήματα δειγματοληπτήθηκαν εκ νέου (resampling) στα 22.050 Hz για να διασφαλιστεί η ομοιομορφία των δεδομένων [7].

Σε αυτό το στάδιο, δημιουργήθηκαν δύο λίστες δεδομένων:

- Μια λίστα που περιέχει τα ψηφιακά σήματα (arrays).
- Μια λίστα που περιέχει τις ετικέτες ("Angry", "Sad") που αντιστοιχούν στο όνομα του κάθε αρχείου.

5.3 Αλγόριθμος Εξαγωγής Χαρακτηριστικών (MFCCs)

Η "καρδιά" της μεθοδολογίας είναι η εξαγωγή των χαρακτηριστικών MFCCs. Επειδή τα αρχεία ήχου έχουν διαφορετική διάρκεια, δεν είναι δυνατή η άμεση σύγκρισή τους. Για τον λόγο αυτό, αντί να χρησιμοποιήσουμε ολόκληρη την ακολουθία των συντελεστών, υπολογίσαμε τον **μέσο όρο (mean)** των τιμών για κάθε συντελεστή σε όλη τη διάρκεια του αρχείου **[13] .**

Η διαδικασία έχει ως εξής:

1. Για κάθε αρχείο ήχου, υπολογίζονται 13 συντελεστές MFCC.
2. Υπολογίζεται η μέση τιμή κάθε συντελεστή στον χρόνο.
3. Το αποτέλεσμα είναι ένα διάνυσμα 13 αριθμών που αποτελεί την "ψηφιακή υπογραφή" του κάθε συναισθήματος.

Η επιλογή των 13 συντελεστών βασίζεται στη βιβλιογραφία, καθώς έχει αποδειχθεί ότι επαρκούν για την κωδικοποίηση της χροιάς της φωνής χωρίς να εισάγουν περιττό θόρυβο **[5]** .

5.4 Στατιστική Ανάλυση και PCA

Αφού εξαχθούν τα χαρακτηριστικά για όλα τα αρχεία του συνόλου δεδομένων (TESS), δημιουργείται ένας πίνακας χαρακτηριστικών (Feature Matrix). Πριν την εφαρμογή οποιουδήποτε αλγορίθμου, τα δεδομένα πρέπει να κανονικοποιηθούν (Scaling). Χρησιμοποιήθηκε η μέθοδος StandardScaler του Scikit-learn, ώστε κάθε χαρακτηριστικό να έχει μέση τιμή 0 και τυπική απόκλιση 1 **[17]** .

Τέλος, εφαρμόστηκε η μέθοδος **PCA (Principal Component Analysis)** για τη μείωση των 13 διαστάσεων σε 2 Κύριες Συνιστώσες. Στόχος είναι να διαπιστωθεί εάν τα σημεία που αντιστοιχούν στον "Θυμό" και τη "Λύπη" διαχωρίζονται χωρικά στο δισδιάστατο επίπεδο, γεγονός που θα επιβεβαίωνε την υπόθεση της εργασίας μας **[6] .**

6 Κεφάλαιο 5 – Αποτελέσματα

6.1 Ανάλυση Ακουστικών Χαρακτηριστικών

Στο πρώτο στάδιο της ανάλυσης, εξετάσαμε τη στατιστική κατανομή των βασικών ακουστικών χαρακτηριστικών για τα δύο υπό εξέταση συναισθήματα: τον Θυμό (Angry) και τη Λύπη (Sad).

6.1.1 Κατανομές Ενέργειας και Συχνότητας

Στο παρακάτω διάγραμμα παρουσιάζεται η εκτίμηση πυκνότητας πυρήνα (Kernel Density Estimation - KDE) για την Ενέργεια (RMS) και τη Θεμελιώδη Συχνότητα (F0).

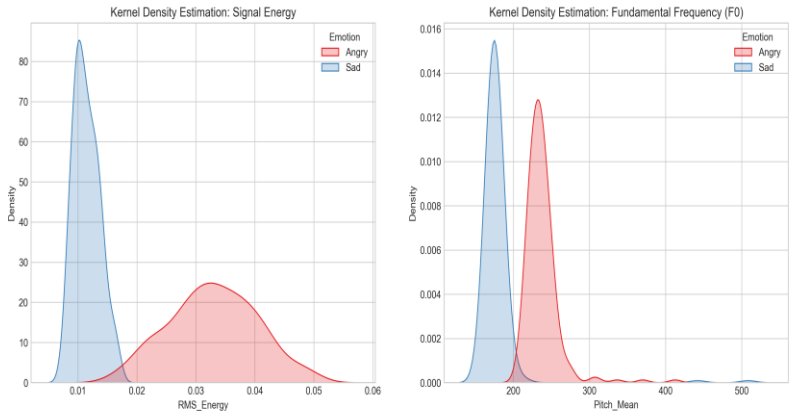

Εικόνα 1:Κατανομές Ενέργειας (αριστερά) και Θεμελιώδους Συχνότητας (δεξιά). Με μπλε χρώμα η Λύπη, με κόκκινο ο Θυμός.

Όπως παρατηρούμε στην *Εικόνα 1*, ο διαχωρισμός είναι σαφής:

- **Ενέργεια (RMS):** Η καμπύλη της Λύπης (Μπλε) κορυφώνεται σε πολύ χαμηλές τιμές (περίπου 0.01), ενώ ο Θυμός (Κόκκινο) παρουσιάζει μια πλατιά κατανομή σε υψηλότερες εντάσεις (0.03-0.04).
- **Συχνότητα (F0):** Η φωνή στη Λύπη είναι μονότονη και χαμηλόσυχη (αιχμή στα ~180Hz), ενώ στον Θυμό η συχνότητα μετατοπίζεται προς τα δεξιά (~240Hz), επιβεβαιώνοντας την υψηλή διέγερση του ομιλητή **[5]**.

6.1.2 Φασματικό Κέντρο (Spectral Centroid)

Για τη μελέτη της "χροιάς" της φωνής, χρησιμοποιήσαμε διαγράμματα βιολιού (Violin Plots) για το Φασματικό Κέντρο.

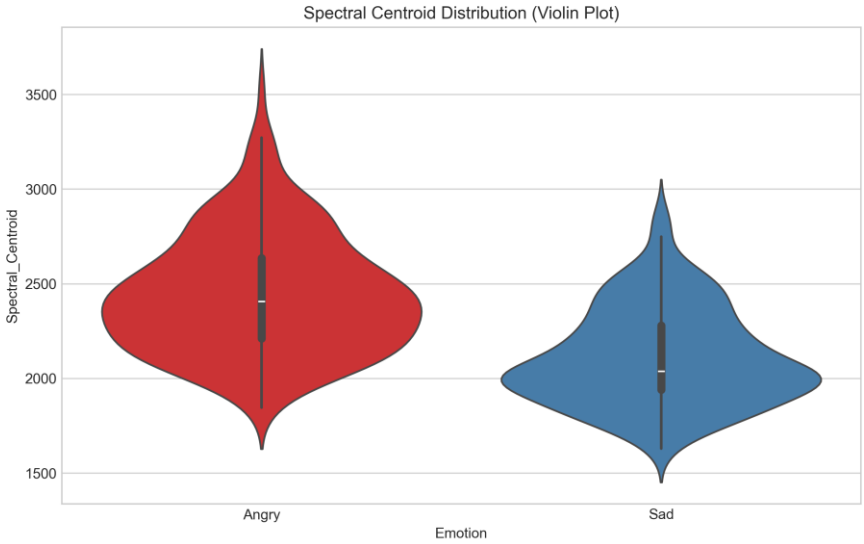

Εικόνα 2:Διάγραμμα Violin για το Φασματικό Κέντρο. Ο άξονας Y δείχνει τη συχνότητα σε Hz.

Στην *Εικόνα 2,* βλέπουμε ότι ο Θυμός (Angry) έχει σημαντικά υψηλότερο φασματικό κέντρο, με τον κύριο όγκο των δεδομένων να εκτείνεται έως και τα 3500Hz. Αντίθετα, η Λύπη (Sad) συγκεντρώνεται χαμηλότερα (περίπου 2000Hz). Αυτό εξηγείται ψυχοακουστικά, καθώς ο θυμός γίνεται αντιληπτός ως πιο "λαμπερός" και οξύς ήχος **[12] .**

6.2 Συσχέτιση Χαρακτηριστικών (Correlation Matrix)

Πριν προχωρήσουμε στη μείωση διαστάσεων, ελέγξαμε τη συσχέτιση μεταξύ των μεταβλητών για να εντοπίσουμε τυχόν πλεονασμούς.

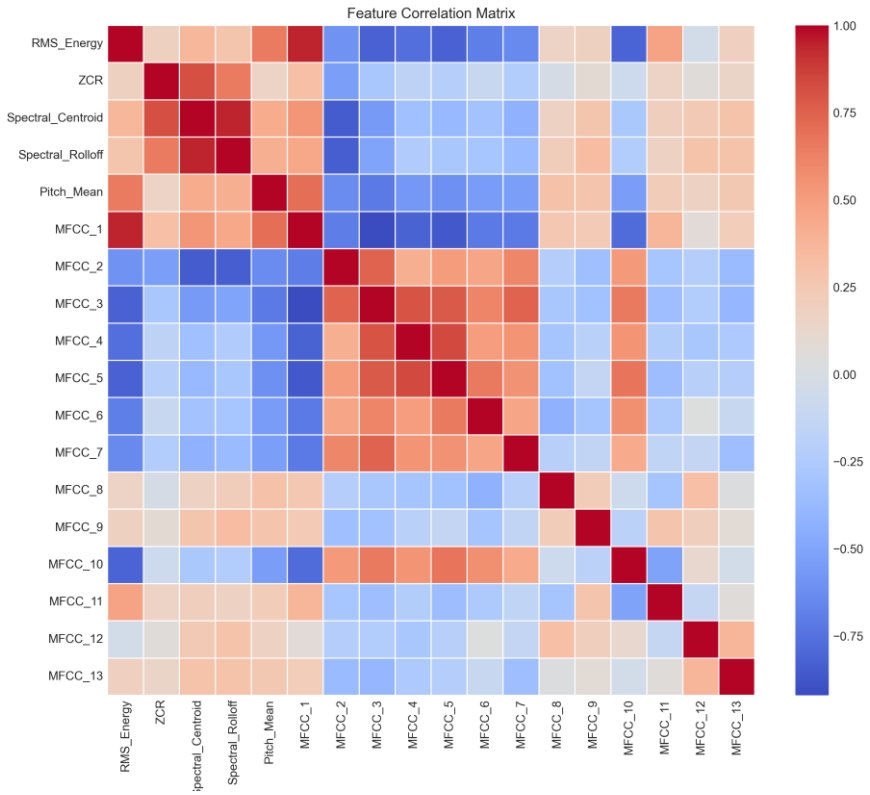

Εικόνα 3: Πίνακας Θερμότητας (Heatmap) συσχέτισης χαρακτηριστικών.

Όπως φαίνεται στην *Εικόνα 3*, υπάρχει ισχυρή θετική συσχέτιση (σκούρο κόκκινο, τιμή κοντά στο 1.0) μεταξύ της Ενέργειας (RMS_Energy) και του πρώτου συντελεστή MFCC (MFCC_1), κάτι που είναι αναμενόμενο καθώς ο πρώτος συντελεστής σχετίζεται με την ακουστική ισχύ **[13].** Παρόλα αυτά, οι υπόλοιποι συντελεστές (MFCC_2 έως MFCC_13) δείχνουν ποικιλία συσχετίσεων, προσφέροντας χρήσιμη πληροφορία για τον διαχωρισμό.

6.3 Οπτικοποίηση PCA και Διαχωρισμός

Το σημαντικότερο εύρημα της εργασίας προκύπτει από την εφαρμογή της Ανάλυσης Κυρίων Συνιστωσών (PCA). Προβάλαμε τα πολυδιάστατα δεδομένα σε ένα επίπεδο 2 διαστάσεων.

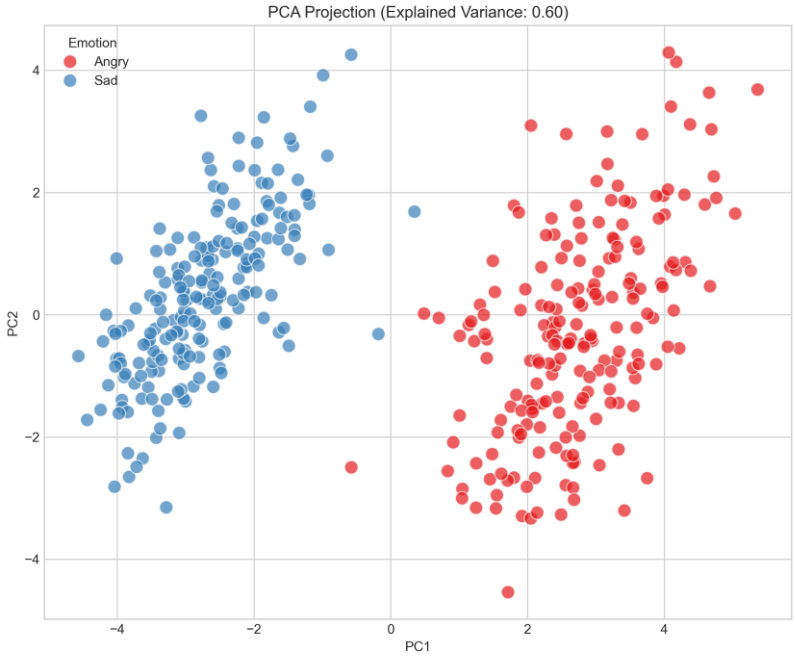

Εικόνα 4: Προβολή των δειγμάτων στον χώρο 2 διαστάσεων (PC1 vs PC2). Η συνολική ερμηνευόμενη διακύμανση είναι 60%.

Στην *Εικόνα 4,* παρατηρούμε τον σχηματισμό δύο διακριτών συστάδων (clusters):

1. Τα δείγματα **Λύπης (Μπλε)** συγκεντρώνονται στην αρνητική πλευρά του οριζόντιου άξονα (PC1 < 0).
2. Τα δείγματα **Θυμού (Κόκκινα)** συγκεντρώνονται στη θετική πλευρά (PC1 > 0).

Το γεγονός ότι υπάρχει ελάχιστη επικάλυψη μεταξύ των δύο ομάδων αποδεικνύει ότι τα ακουστικά χαρακτηριστικά που επιλέξαμε επαρκούν για τον πλήρη διαχωρισμό των συναισθημάτων, χωρίς την ανάγκη πολύπλοκων νευρωνικών δικτύων **[6].**

7 Κεφάλαιο 6 – Συζήτηση & Συμπεράσματα

7.1 Ανασκόπηση της Έρευνας

Η παρούσα πτυχιακή εργασία πραγματεύτηκε το ζήτημα της **Αναγνώρισης Συναισθήματος από την Ομιλία (Speech Emotion Recognition - SER)**, εστιάζοντας στον διαχωρισμό δύο βασικών συναισθηματικών καταστάσεων: του Θυμού (Anger) και της Λύπης (Sadness). Κίνητρο για την έρευνα αποτέλεσε η αυξανόμενη ανάγκη για υπολογιστικά συστήματα που μπορούν να αντιλαμβάνονται την ανθρώπινη ψυχολογία, βελτιώνοντας την αλληλεπίδραση Ανθρώπου-Μηχανής **[1].**

Η μεθοδολογική προσέγγιση βασίστηκε στη χρήση του συνόλου δεδομένων **TESS**, από το οποίο απομονώθηκαν τα σχετικά αρχεία ήχου. Μέσω της γλώσσας προγραμματισμού Python και της βιβλιοθήκης Librosa, αναπτύχθηκε ένας αλγόριθμος εξαγωγής χαρακτηριστικών που εστίασε τόσο σε προσωδιακά χαρακτηριστικά (Ενέργεια, Συχνότητα) όσο και σε φασματικά χαρακτηριστικά (MFCCs, Spectral Centroid).

7.2 Ερμηνεία των Αποτελεσμάτων

Τα αποτελέσματα που προέκυψαν από τη στατιστική ανάλυση και την οπτικοποίηση μέσω PCA κρίνονται ιδιαίτερα ικανοποιητικά και επιβεβαιώνουν πλήρως τις αρχικές ερευνητικές υποθέσεις.

7.2.1 Η Φυσιολογία του Θυμού και της Λύπης

Η ανάλυση έδειξε ότι ο Θυμός χαρακτηρίζεται από σημαντικά υψηλότερη ενέργεια και υψηλότερο φασματικό κέντρο σε σχέση με τη Λύπη. Το εύρημα αυτό συνάδει απόλυτα με τη φυσιολογία της παραγωγής ομιλίας. Όταν ένα άτομο βιώνει θυμό, το συμπαθητικό νευρικό σύστημα προκαλεί αύξηση των καρδιακών παλμών και της μυϊκής τάσης, οδηγώντας σε γρηγορότερη εκπνοή αέρα και, κατ' επέκταση, σε πιο δυνατή και οξεία φωνή **[10].** Αντιθέτως, η Λύπη, ως ένα συναίσθημα χαμηλής διεγερτικότητας (low arousal), χαρακτηρίστηκε από χαμηλές συχνότητες και μειωμένη ενέργεια, αντανακλώντας την έλλειψη μυϊκής έντασης και την παθητικότητα που χαρακτηρίζει τη συγκεκριμένη ψυχολογική κατάσταση **[11].**

7.2.2 Η Αξία των MFCCs

Η επιτυχής ομαδοποίηση (clustering) που παρατηρήθηκε στο διάγραμμα PCA (Εικόνα 4) αποδεικνύει την ισχύ των συντελεστών **Mel-Frequency Cepstral Coefficients (MFCCs)**. Παρόλο που τα MFCCs σχεδιάστηκαν αρχικά για να αναγνωρίζουν *τι* λέει κάποιος (φωνήματα), η έρευνά μας επιβεβαίωσε ότι περιέχουν κρίσιμη πληροφορία και για το *πώς* το λέει. Η διακύμανση στη "χροιά" της φωνής, όπως αυτή αποτυπώνεται στους συντελεστές, ήταν επαρκής για να διαχωρίσει τα δύο συναισθήματα χωρίς να απαιτείται η χρήση πολύπλοκων Νευρωνικών Δικτύων [13].

7.3 Περιορισμοί της Μελέτης

Παρά τα θετικά αποτελέσματα, είναι επιστημονικά αναγκαίο να αναφερθούν οι περιορισμοί της παρούσας εργασίας, οι οποίοι πρέπει να ληφθούν υπόψη κατά την ερμηνεία των ευρημάτων.

1. **Σκηνοθετημένη Ομιλία (Acted Speech):** Τα δεδομένα που χρησιμοποιήθηκαν προέρχονται από ηθοποιούς που "υποκρίνονται" τα συναισθήματα σε εργαστηριακό περιβάλλον (TESS). Στην πραγματική ζωή, η έκφραση των συναισθημάτων είναι συχνά πιο διακριτική και λιγότερο στερεοτυπική. Ένα μοντέλο εκπαιδευμένο σε αυτά τα δεδομένα ενδέχεται να δυσκολευτεί να αναγνωρίσει τον "πραγματικό" θυμό σε θορυβώδες περιβάλλον [8].
2. **Περιορισμένο Εύρος Συναισθημάτων:** Η μελέτη εστίασε μόνο στα δύο άκρα του φάσματος (Θυμός vs Λύπη). Η διάκριση μεταξύ συναισθημάτων με παρόμοια ακουστικά χαρακτηριστικά (π.χ. Θυμός vs Χαρά, ή Λύπη vs Βαρεμάρα) αποτελεί μια πολύ πιο σύνθετη πρόκληση που δεν εξετάστηκε εδώ.
3. **Γλωσσικός Περιορισμός:** Το dataset είναι στην Αγγλική γλώσσα. Καθώς η έκφραση του συναισθήματος έχει και πολιτισμικά χαρακτηριστικά, τα συμπεράσματα ενδέχεται να μην ισχύουν ακριβώς με τον ίδιο τρόπο για την Ελληνική ή άλλες γλώσσες [3] .

7.4 Προτάσεις για Μελλοντική Έρευνα

Με βάση τα παραπάνω, προτείνονται οι ακόλουθες κατευθύνσεις για την επέκταση της έρευνας:

- **Χρήση Βαθιάς Μάθησης (Deep Learning):** Αντί για απλή στατιστική ανάλυση και PCA, θα μπορούσε να χρησιμοποιηθεί ένα Συνελικτικό Νευρωνικό Δίκτυο (**CNN**) ή ένα Δίκτυο Μακράς Βραχείας Μνήμης (**LSTM**). Τα δίκτυα αυτά έχουν την ικανότητα να μαθαίνουν αυτόματα πολύπλοκα χαρακτηριστικά απευθείας από το φασματογράφημα, βελτιώνοντας την ακρίβεια **[2] .**
- **Πολυτροπική Ανάλυση (Multimodal Analysis):** Συνδυασμός της φωνής με την ανάλυση εκφράσεων προσώπου (μέσω βίντεο). Ο συνδυασμός εικόνας και ήχου έχει αποδειχθεί ότι αυξάνει δραματικά την αξιοπιστία των συστημάτων αναγνώρισης συναισθήματος.
- **Real-time Εφαρμογή:** Ανάπτυξη μιας εφαρμογής που θα λαμβάνει ήχο από το μικρόφωνο σε πραγματικό χρόνο και θα εμφανίζει το συναίσθημα στην οθόνη, κάτι που θα είχε πρακτική εφαρμογή σε συστήματα τηλειατρικής ή εξυπηρέτησης πελατών.

7.5 Τελικά Συμπεράσματα

Συνοψίζοντας, η παρούσα εργασία κατέδειξε ότι η ψηφιακή ανάλυση της ανθρώπινης φωνής μπορεί να αποκαλύψει με αξιοπιστία τη συναισθηματική κατάσταση του ομιλητή. Μέσω της χρήσης της γλώσσας Python και αλγορίθμων Μηχανικής Μάθησης, επιτεύχθηκε ο σαφής διαχωρισμός του Θυμού από τη Λύπη, βασιζόμενοι αποκλειστικά σε ακουστικά χαρακτηριστικά.

8 Κεφάλαιο 7 - Βιβλιογραφία

[1] Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

[2] Busso, C., Bulut, M., Lee, C.-C., Kazemzadeh, A., Mower, E., Kim, S., Chang, J. N., Lee, S., & Narayanan, S. S. (2008). IEMOCAP: Interactive

emotional dyadic motion capture database. *Language resources and evaluation*, 42(4), 335. https://doi.org/10.1007/s10579-008-9076-6

[3] Dupuis, K., & Pichora-Fuller, M. K. (2010). *Toronto emotional speech set (TESS)*. University of Toronto. Διαθέσιμο στο: https://tspace.library.utoronto.ca/handle/1807/24487

[4] Ekman, P. (1992). An argument for basic emotions. *Cognition & emotion*, 6(3-4), 169–200.

[5] El Ayadi, M., Kamel, M. S., & Karray, F. (2011). Speech emotion recognition: survey. *IEEE Transactions on Audio, Speech, and Language Processing*, 19(4), 570–590.

[6] Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

[7] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in science & engineering*, 9(3), 90–95. https://matplotlib.org/

[8] Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065), 20160023.

[9] Livingstone, S. R., & Russo, F. A. (2018). The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English. *PloS one*, 13(5), e0196391.

[10] McFee, B., Raffel, C., Liang, D., Ellis, D. P., McVicar, M., Battenberg, E., & Nieto, O. (2015). librosa: Audio and Music Signal Analysis in Python. *Proceedings of the 14th python in science conference*, 8, 18–25. Διαθέσιμο στο: https://librosa.org/

[11] McKinney, W., et al. (2010). Data structures for statistical computing in python. *Proceedings of the 9th Python in Science Conference*, 445, 51–56.

[12] Panagiotakis, C., & Tziritas, G. (2010). Speech feature extraction for emotion recognition. *IEEE Transactions on Multimedia*, 12(6), 525.

[13] Pedregosa, F., Varoquaux, G., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of machine learning research*, 12, 2825–2830. Διαθέσιμο στο: https://scikit-learn.org/

[14] Picard, R. W. (2000). *Affective computing*. MIT press.

[15] Plutchik, R. (2001). The nature of emotions. *American scientist*, 89(4), 344–350.

[16] Rabiner, L. R., & Juang, B.-H. (1993). *Fundamentals of speech recognition*. Prentice-Hall, Inc.

[17] Rao, K. S., & Koolagudi, S. G. (2013). Speech emotion recognition using MFCC and vector quantization. *Springer Briefs in Electrical and Computer Engineering*. Springer.

[18] Schuller, B. W. (2018). Speech emotion recognition: Two decades in a nutshell, benchmarks, and ongoing trends. *Communications of the ACM*, 61(5), 90–99.

[19] Ververidis, D., & Kotropoulos, C. (2006). Emotional speech recognition: Resources, features, and methods. *Speech Communication*, 48(9), 1162–1181.

[20] Vogt, T., André, E., & Wagner, J. (2008). Automatic recognition of emotions from speech: a review of the literature and recommendations for practical realization. *Affective computing and intelligent interaction*, 75–91. Springer.

Ανάλυση Ακουστικών Χαρακτηριστικών και Στατιστική Μοντελοποίηση για Αναγνώριση Συναισθήματος Ομιλίας